

HE Trebinje I

Predikcija vremenskih serija

Regresija agregata i klasifikacija rizika preлива

Projekat iz predmeta SAUSAU

Nivo 3 — sopstveni dataset i trening modela

Autor: Đorđe Đaković

2026

1. Uvod

Sistem masinskog ucenja za upravljanje hidroelektranom Trebinje I. Projekat simulira rad dispecera koji na osnovu istorijskih i trenutnih podataka donosi dve kljucne odluke:

- Regresija — koliko od ukupno 3 turbinska agregata treba aktivirati
- Klasifikacija — da li postoji rizik od prelivanja Bileckog jezera (0/1)

1.1 Opis problema

Planiranje angazmana agregata — dispecer svaki dan mora odluciti koliko od ukupno 3 turbinska agregata treba aktivirati, uzimajuci u obzir trenutni vodostaj jezera, dotok vode, pritisak elektricne mreze i vremensku prognozu. Prevelik broj aktivnih agregata nepotrebno prazni rezervoar, a premali ne iskoristava dostupnu energiju.

Detekcija rizika od preliva — kada nivo jezera poraste iznad maksimalno dozvoljene kote, dolazi do nekontrolisanog prelivanja vode preko brane. Preliv je izuzetno opasan dogadjaj koji moze uzrokovati trajno ostenjenje konstrukcije brane, poplavu nizvodnih naselja i gubitak ljudskih zivota. Dispecer mora blagovremeno prepoznati rizik i pravovremeno reagovati.

2. Dataset

Sopstveno prikupljeni i ocisceni podaci o Bileckom jezeru (HE Trebinje I):

- Period: 2000–2027 (~10,000 dana)
- Atributi: Vodostaj, dotok, padavine, temperatura, doba godine, pritisak mreze, promjena vodostaja
- Target 1 (regresija): Angazovani_Agregati (0–3)
- Target 2 (klasifikacija): Preliv_Status (0/1, svega 1.28% pozitivnih — ekstreman imbalance)

2.1 Atributi

Atribut	Opis	Opseg
Vodostaj_Bileca	Nivo vode u jezeru (m)	300–420
Dotok_Prethodni_Dan	Dotok vode prethodnog dana (m³/s)	0–2000
Padavine_Trebinje	Padavine u Trebinju (mm)	0–500
Temperatura_Vazduha	Temperatura vazduha (°C)	-30–50
Doba_Godine	Sezona (Zima/Proljece/Ljeto/Jesen)	4 kategorije
Pritisak_Mreze	Pritisak elektricne mreze	3 kategorije
Padavine_Sutra	Prognoza padavina za sutra (mm)	0–500
Padavine_Za2Dana	Prognoza padavina za 2 dana (mm)	0–500
Promjena_Vodostaja	Dnevna promjena vodostaja (m)	-5–5

3. Struktura projekta

```
PROJEKTOVANJE/  
data/  
  hetl.csv      # originalni dataset  
  hetl_clean.csv  # ocisceni dataset  
  splits.joblib  # train/val/test splitovi  
models/         # sacuvani modeli i enkoderi  
plots/          # generisani grafici  
app/  
  app.py        # Streamlit aplikacija
```

```
src/
config.py      # konstante
data_prep.py   # KORAK 1: priprema podataka
train.py       # KORAK 2: treniranje
evaluate.py    # KORAK 3: evaluacija
predict.py     # KORAK 4: 7-dnevna prognoza
metrics.json   # sve metrike
tumacenje.txt  # tumacenje rezultata
dokumentacija.pdf # ova dokumentacija
```

4. Metodologija

- Split: 70/10/20 (train/validation/test), stratifikovan po Preliv_Status
- random_state=42 svuda za reproducibilnost
- SMOTE samo na train skupu — unutar ImbPipeline, nikad na val/test
- Prag odluke optimizovan na validation skupu za svaku varijantu posebno: sweep 0.01–0.99
- Kriterijum: max recall uz precision >= 5%
- Validation za sve odluke; test skup evaluiran samo jednom
- Recall iznad svega — propusten preliv moze osetiti branu

5. Varijante klasifikatora

Istrazivano je 7 varijanti klasifikacije kako bi se prag odluke priblizio 0.5:

Kod	Naziv	Opis
A_raw	XGBoost BEZ kalibracije	Sirovi predict_proba score-ovi
B_platt	XGBoost + Platt	Sigmoid kalibracija
C_iso	XGBoost + isotonic	Isotonic kalibracija (original)
D_undersample	Undersampling + XGBoost	RandomUnderSampler(0.3)
E_iforest	Isolation Forest	Anomaly detection
RF_ref	RandomForest + SMOTE	Referentni model
LR_ref	LogisticRegression + SMOTE	Referentni model

6. Rezultati

6.1 Regresija (test skup)

Model	MAE	RMSE	R²
XGBoost (svi)	0.126	0.242	0.884
XGBoost (top5)	0.147	0.276	0.849
Random Forest	0.123	0.248	0.878
Baseline	0.629	-	-

6.2 Klasifikacija — poređenje varijanti (test skup)

Varijanta	Prag	Recall	Prec	F1	PR-AUC	TP	FP	TN
Undersampling + XGBoos	0.100	0.962	0.070	0.131	0.066	25/26	332	1642
XGBoost + isotonic	(or 0.030	0.885	0.073	0.134	0.114	23/26	294	1680
RandomForest + SMOTE	0.030	0.885	0.067	0.125	0.084	23/26	319	1655

LogisticRegression + S	0.050	0.615	0.067	0.120	0.079	16/26	224	1750
Isolation Forest	0.090	0.462	0.041	0.075	0.079	12/26	284	1690
XGBoost BEZ kalibracij	0.030	0.308	0.078	0.124	0.104	8/26	95	1879
XGBoost + Platt (sigmo	0.060	0.077	0.125	0.095	0.108	2/26	14	1960

6.3 Selekcija atributa

Najuticajnji atributi (prosek feature importance regresije i klasifikacije):

1. Dotok_Prethodni_Dan = 0.5246 +
2. Pritisak_Mreze_enc = 0.2287 +
3. Promjena_Vodostaja = 0.0820 +
4. Padavine_Sutra = 0.0362 +
5. Padavine_Trebinje = 0.0360 +
6. Vodostaj_Bileca = 0.0327 -
7. Temperatura_Vazduha = 0.0281 -
8. Padavine_Za2Dana = 0.0250 -
9. Doba_Godine_enc = 0.0067 -

Zadržano (top 5): Dotok_Prethodni_Dan, Pritisak_Mreze_enc, Promjena_Vodostaja, Padavine_Sutra, Padavine_Trebinje

Odbaceno (4): Vodostaj_Bileca, Temperatura_Vazduha, Padavine_Za2Dana, Doba_Godine_enc

7. Pokretanje

Instalacija zavisnosti:

```
pip install -r requirements.txt
```

Pipeline (redom):

```
python src/data_prep.py # KORAK 1: priprema, validacija, split
python src/train.py # KORAK 2: treniranje 7 varijanti
python src/evaluate.py # KORAK 3: evaluacija, metrike, grafici
python src/predict.py # KORAK 4: demo 7-dnevne prognoze
```

Streamlit aplikacija:

```
streamlit run app/app.py
```

```
python -m streamlit run app/app.py
```

8. Tehnologije

- Python 3.10+
- scikit-learn 1.3+ — Random Forest, Logistic Regression, LabelEncoder
- imbalanced-learn — SMOTE, RandomUnderSampler
- XGBoost 2.0+ — XGBRegressor, XGBClassifier
- pandas, numpy, matplotlib, seaborn
- Streamlit — interaktivna vizualizacija
- joblib — serijalizacija modela

9. Metrike

- Regresija: MAE, RMSE, R^2
- Klasifikacija: Recall, Precision, F1, PR-AUC, Confusion Matrix
- Accuracy se ne koristi — baseline daje 98.7% accuracy ali recall=0

10. Zakljucak

Cilj projekta je bio istraziti da li se prag odluke klasifikatora moze pribliziti vrednosti 0.5 primenom razlicitih tehnika kalibracije i balansiranja podataka, uz ocuvanje visokog recall-a (detekcije rizika od preлива). Najuspesnije varijante su Undersampling + XGBoost (prag=0.100, recall=0.962) i XGBoost + isotonic (prag=0.030, recall=0.885). Za regresiju, XGBoost postize MAE=0.126 i $R^2=0.884$, sto znacajno nadmasuje baseline (MAE=0.629).