

HE TREBINJE I

ML sistem za planiranje agregata i detekciju rizika od preliva

Bilečko jezero — period 2000–2027

SAUSAU — Projektna dokumentacija

Softverski algoritmi u sistemima automatskog upravljanja — Nivo 3

Jun 2026.

1. Opis zadatka

Svakodnevno upravljanje hidroelektranom podrazumijeva donošenje dvije kritične operativne odluke:

- **Planiranje angažmana agregata** — dispečer svaki dan mora odlučiti koliko od ukupno 3 turbinska agregata treba aktivirati, uzimajući u obzir trenutni vodostaj jezera, dotok vode, pritisak električne mreže i vremensku prognozu. Prevelik broj aktivnih agregata nepotrebno prazni rezervoar, a premali ne iskorištava dostupnu energiju.
- **Detekcija rizika od preliva** — kada nivo jezera poraste iznad maksimalno dozvoljene kote, dolazi do nekontrolisanog preliivanja brane, što može dovesti do trajnog oštećenja brane i poplave okolnih naselja. Dispečer mora naravno donijeti pravilnu odluku kako ne bi došlo do preliivanja brane, mora prepoznati rizik od preliva i pravilno reagovati

Cilj projekta je razvoj sistema mašinskog učenja koji simulira rad dispečera u hidroelektrani Trebinje I na osnovu dnevnih podataka o Bilečkom jezeru. Sistem rješava dva zadatka:

- **Regresija** — predikcija broja turbinskih agregata koje treba angažovati (0–3) za narednih 7 dana.
- **Klasifikacija** — predikcija rizika od preliivanja Bilečkog jezera (0 = nema rizika, 1 = rizik).

Postupak izrade projekta prolazi kroz više faza o čemu će više riječi biti u nastavku.

Struktura projekta:

```
HET/
├─ src/
│   ├── config.py           # konstante i validacioni opsezi
│   ├── data_prep.py        # čišćenje, enkodiranje, split 70/10/20
│   ├── train.py             # treniranje svih modela i varijanti
│   ├── evaluate.py          # evaluacija, grafici, metrics.json
│   └── predict.py           # 7-dnevna prognoza (forecast_7days)
├─ app/app.py               # Streamlit aplikacija
├─ data/                    # hetI.csv, hetI_clean.csv, splits.joblib
├─ models/                  # joblib modeli, threshold.json, variants.json
└─ plots/                   # generisani grafici
```

2. Postupak

1. Preprocesiranje

Na početku rada izvršeno je pripremanje skupa podataka za obuku modela. Realizovano je sljedeće:

- **Uklanjanje null vrijednosti i duplikata** — eliminisani svi redovi s praznim poljima ili ponavljajućim zapisima.
- **Validacija kategorija** — Doba_Godine i Pritisak_Mreze moraju imati poznate vrijednosti.
- **Fizikalni opsezi** — svaki numerički atribut provjeren prema definisanim granicama iz config.py; redovi van opsega su eliminisani.
- **Label enkodiranje** — kategorički atributi Doba_Godine i Pritisak_Mreze numerički enkodovani i sačuvani kao joblib enkoderi radi konzistentnosti pri predikciji.

2. Podjela podataka

Korišten je stratifikovani split **70 / 10 / 20** (trening / validacija / test) po Preliv_Status. Stratifikacija je neophodna jer pozitivna klasa čini svega 1.28% uzoraka. Validation skup se koristi za sve odluke o pragovima i odabiru varijanti. Test skup je evaluiran samo jednom.

Skup	Udio	Namjena
Train	70 %	Treniranje svih modela
Validation	10 %	Optimizacija pragova, odabir varijante
Test	20 %	Finalna evaluacija — korišten samo jednom

3. Modelovanje i izbor metrike

Regresija

Isprobana su dva modela uz DummyRegressor kao baseline. XGBoost je optimizovan GridSearchCV-om (3-fold CV) po prostoru {n_estimators, max_depth, learning_rate}. Dodatno, XGBoost je treniran i na skupu od samo 5 najvažnijih atributa.

Model	MAE	RMSE	R ²
XGBoost (svi atributi)	0.126	0.242	0.884
Random Forest (svi attr.)	0.123	0.248	0.878
XGBoost (top 5 atributa)	0.147	0.276	0.849
Baseline (srednja vr.)	0.629	0.710	≈ 0.000

$R^2 \approx 0.88$ znači da model objašnjava 88% varijanse broja angažovanih agregata. Prosječna greška od 0.12–0.13 agregata je operativno zanemarljiva.

Klasifikacija

Od ~10.000 uzoraka, samo **1.28% su dani s prelivanjem**. DummyClassifier koji uvijek predviđa 'nema preliva' postiže accuracy 98.7% ali recall 0 — accuracy je stoga potpuno besmislena metrika za ovaj problem.


Odabrane metrike:

- **Recall (primarna)** — procenat preliva koje je model uhvatio. Propušten preliv je katastrofalna greška jer može trajno oštetiti branu, dok lažni alarm samo lažno opomene dispečera da mora obratiti pažnju. False Negative je mnogo skuplja greška od False Positive.
- **PR-AUC** — površina ispod Precision-Recall krive, neovisna o pragu odluke. Ključna metrika za prag-nezavisno poređenje varijanti.
- **F1** — harmonijska sredina između Precision i Recall; korišćen kao dopunska referenca.

Istraživano je **7 varijanti klasifikatora** s ciljem pronalaska pristupa koji bi dao prag odluke što bliži 0.5, uz što viši recall:

Varijanta	Naziv	Opis
A — Raw	XGBoost BEZ kalibracije	Sirove predict_proba vrijednosti, bez post-processing kalibracije
B — Platt	XGBoost + Platt	Sigmoid kalibracija vjerovatnoća (CalibratedClassifierCV, method='sigmoid')
C — Isotonic	XGBoost + isotonic	Isotonic regression kalibracija — originalni pristup projekta
D — Undersample	Undersampling + XGBoost	RandomUnderSampler(ratio=0.3) na trening skupu, XGBoost bez kalibracije
E — IForest	Isolation Forest	Anomaly detection — treniran isključivo na negativnoj klasi (contamination=0.02)
RF ref	RandomForest + SMOTE	Random Forest + SMOTE oversampling + isotonic kalibracija
LR ref	LogReg + SMOTE	Logistička regresija + SMOTE + isotonic kalibracija


Grafik ispod prikazuje recall, precision i pragove odluke za sve varijante na validation skupu:



Slika 1 — Poređenje varijanti: recall, precision i pragovi odluke (validation skup)

4. Podešavanje pragova


Za svaku varijantu prikazan je trade-off između recall-a i precision-a kroz cijeli opseg pragova. Sweep se radi na validation skupu, a odabrani optimalni prag je označen isprekidanom linijom:




Slika 2 — Sweep pragova odluke po varijantama (validation skup)

5. Feature Importance

Importance je računata kao prosjek XGBoost Regresora i XGBoost Klasifikatora (C_iso varijanta) — normalizovani gain koji mjeri koliko se greška smanji pri grananju po određenom atributu, sumirano kroz sva stabla:



Slika 3 — Feature importance: zajednicki rang i importance regresora posebno



Slika 4 — Feature importance XGBoost klasifikatora (C_iso varijanta)

Ra ng	Atribut	Importa nce	Status
1	Dotok_Prethodni_Da n	0.5246	Zadržan — dominantan; dotok direktno određuje kapacitet i signalizira punjenje jezera
2	Pritisak_Mreze_enc	0.2287	Zadržan — visok pritisak mreže zahtijeva više angažovanih agregata
3	Promjena_Vodostaja	0.0820	Zadržan — trend kretanja jezera ključan signal za detekciju rizika
4	Padavine_Sutra	0.0362	Zadržan — prognoza padavina omogućava proaktivno planiranje
5	Padavine_Trebinje	0.0360	Zadržan — lokalne padavine direktno doprinose dotoku
6	Vodostaj_Bileca	0.0327	Odbačen — redundantno uz Promjena_Vodostaja


Rang	Atribut	Importance	Status
7	Temperatura_Vazduha	0.0281	Odbačen — slaba direktna veza s brojem agregata
8	Padavine_Za2Dana	0.0250	Odbačen — kratki horizont donosi više šuma nego signala
9	Doba_Godine_enc	0.0067	Odbačen — sezonalnost implicitno sadržana u dotoku

Redukcija na top 5 ne mijenja recall (ostaje 0.885), ali PR-AUC pada za 0.041. Za produkciju su odabrani svi atributi.

4. Rezultati i zaključci

Distribucija vjerovatnoća


Histogrami prikazuju raspodjelu izlaznih score-ova za pozitivne (preliv) i negativne (bez preliva) primjere na test skupu. Idealan model bi imao jasno razdvojene distribucije:



Slika 5 — Distribucija predikcija po varijantama, log skala (test skup)

Confusion matrice

Matrice konfuzije za sve varijante na test skupu:



Slika 6 — Confusion matrice za sve varijante (test skup)

Poredjenje varijanti na test skupu

#	Varijanta	Prag	Recall	Precision	F1	PR-AUC	Detektovano
1	Undersampling + XGBoost	0.100	0.962	0.070	0.131	0.066	25 / 26
2	XGBoost + isotonic	0.030	0.885	0.073	0.134	0.114	23 / 26
3	RandomForest + SMOTE	0.030	0.885	0.067	0.125	0.084	23 / 26
4	LogReg + SMOTE	0.050	0.615	0.067	0.120	0.079	16 / 26
5	Isolation Forest	0.090	0.462	0.041	0.075	0.079	12 / 26
6	XGBoost BEZ kalibracije	0.030	0.308	0.078	0.124	0.104	8 / 26
7	XGBoost + Platt	0.060	0.077	0.125	0.095	0.108	2 / 26

Zaključci

- **Undersampling + XGBoost je pobjednički model** — recall 0.962, detektovano 25 od 26 preliva na test skupu. Propušten samo 1 preliv.
- **Dominantni prediktor** — Dotok_Prethodni_Dan (importance 0.52); dotok direktno određuje kapacitet i nivo jezera.
- **Redukcija atributa** — ne mijenja recall, ali PR-AUC klasifikatora pada za 0.041; za produkciju su zadržani svi atributi.
- **Cilj eksperimenta** — pribliziti prag odluke vrijednosti 0.5. Varijanta D postiže prag 0.100, znatno bliže od 0.030 originalnog pristupa, ali potpuna kalibracija ostaje otvoren problem.

Preporuke za unaprjeđenje

- Primijeniti SMOTE + undersampling kombinovano — potencijal za povećanje PR-AUC uz zadržan recall.
- Razmotriti vremenski svjesni split (stariji datumi = trening, noviji = test) radi sprečavanja vremenskog curenja podataka.
- Ensemble pristup: kombinovati C_iso i D_undersample glasanjem — smanjiti lažne alarme uz zadržan visok recall.
- Prikupiti više podataka o prelivima — ~130 pozitivnih primjera je mali uzorak za robusno generalizovanje.

5. Deployment

Streamlit aplikacijom omogućen je unos meteoroloških i operativnih podataka za narednih 7 dana i predviđanje broja angažovanih agregata i rizika od preliva u realnom vremenu.

- Pritisnuti "Učitaj demo" za automatsko popunjavanje — ili ručno unijeti podatke za 7 dana.
- Pritisnuti "Prognoza" — model predviđa broj agregata i P(preliv) za svaki dan.
- Rezultati su prikazani u tabeli i kombinovanom grafiku.
- Ako je rizik preliva detektovan za neki dan, prikazuje se alarm s listom rizičnih dana.

Pokretanje aplikacije:

```
uv run streamlit run app/app.py
```

SAUSAU 2026 — Softverski algoritmi u sistemima automatskog upravljanja